멀티모달 SAE 성질 유도 (1).... PDF

2602.06218v2.pdf PDF

2512.05534v3.pdf PDF

2506.15963v2.pdf PDF

혹시 이 세 논문과 내가 "멀티모달 SAE 성질 유도 (1).pdf"을 context로 고려해서

지금 내가 이론적으로 보이고 싶은 것은 **"멀티뷰 구조를 이용한 보조 목적이 SAE의 비식별성을 줄이고, shared GT feature 쪽으로 해를 앵커링한다"**인데

첫째, 왜 멀티모달 SAE가 더 어렵나 -- reconstruction만 최적화하면 GT monosemantic feature와 learned dictionary가 정렬될 보장이 없고, multimodal에서는 latent feature 수와 interference가 커져 split dictionary나 polysemantic failure가 더 쉽게 생긴다

둘째, 어떤 보조 목적이 그 문제를 줄일 수 있나 -- 이미지 전용, 텍스트 전용, 공유 latent block을 나누고, 특히 공유 block에 대해 pair 간 activation agreement를 주는 구조를 제안합니다. 즉, 이미지 임베딩과 텍스트 임베딩이 같은 shared generative factor를 가질 때, learned shared code도 pair에서 같아지게 만들고 싶다는 것

셋째, 그 보조 목적이 실제로 무엇을 보장하나 -- 이게 제일 어려운 건데 지금은 ** reconstruction만 있을 때 남아 있던 비식별 해집합** 이렇게 가고 있는데 뭔가 https://arxiv.org/pdf/2506.15963v2를 참고해서 다른 유도를 해야하나 싶어. 그니까 결국은 "멀티뷰 구조를 이용한 보조 목적이 SAE의 비식별성을 줄이고, shared GT feature 쪽으로 해를 앵커링한다"를 어떻게 보여야하냐가 고민이야.

Top-K sparsity activation을 쓴다는 설정에서 이론적 유도를 하고 싶은데 꽤 막히는 것 같아.
일단 내가 보이고 싶은 "멀티뷰 구조를 이용한 보조 목적이 SAE의 비식별성을 줄이고, shared GT feature 쪽으로 해를 앵커링한다"가 진짜 이론적으로 보일 수 있는 게 맞는건가? 맞다면 어떤 현설적인 세팅/가정 하에서?

만약 보일 수 있다면 현설적인 세팅/가정 하에서 complete proof 형태로 논문에 바로 담을 수 있을 수준의 완성도로 definition, assumption, theorem을 유도해줄 수 있을까?

Thought for 40m 48s ›

네. 다만 명제를 **조금 더 정확하게** 잡아야 합니다.

업로드한 세 논문을 같이 보면, 지금 네가 보이고 싶은 방향은 충분히 이론화 가능합니다. 다만 정직하게 말하면 **"reconstruction + pairwise shared-agreement만으로 항상 identifiability"** 는 너무 강한 명제입니다. 2512.05534는 SDL/SAE류 목적이 구조적으로 underdetermined이고 spurious partial minima가 많아서 anchoring이 필요하다고 보고, 2506.15963는 표준 SAE가 일반적으로 GT monosemantic feature를 완전히 복원하지 못하고 extreme sparsity에서만 유일 복원이 가능하다고 분석합니다. 2602.06218는 멀티모달 쪽에서 cross-modal redundancy를 이용한 alignment regularizer가 toy data에서 GT bimodal atoms recovery를 실제로 돕고, 그 가정이 깨지면 거의 중립적임을 보여줍니다. 또 2512.05534와 2506.15963 모두 TopK/JumpReLU류를 같은 threshold/selection 계열 activation으로 다룹니다. 2512.05534v3 2506.15963v2 2602.06218v2

그래서 논문에서 가장 강하고도 방어 가능한 claim은 다음처럼 쓰는 게 맞습니다.

1. **reconstruction-only는 비식별**이다.
2. **멀티뷰 agreement는 exact-reconstruction 해집합을 줄인다**. 정확히는, shared code가 private nuisance에 의존하는 해를 제거한다.
3. **Top-K만 쓸 때 agreement alone은 부족**하다. shared block을 실제로 쓰게 만드는 추가 구조가 필요하다.
4. 그 추가 구조(가장 깔끔한 건 blockwise Top-K와 singleton shared anchor states)까지 두면, **shared decoder atom이 GT shared atom에 perm/positive-scale까지 일치**한다.

아래는 그걸 바로 논문에 넣을 수 있게 정리한 버전입니다.
핵심은 **population-level exact theorem**과 **finite-λ approximate theorem**을 둘 다 주는 겁니다.

---

1. 논문용 세팅

Definition 1 (Shared-private multiview generative model)

짝지어진 두 뷰 (x, y)가 다음과 같이 생성된다고 하자:

$$x = A_s z + A_x \xi \in \mathbb{R}^{d_x}, \qquad y = B_s z + B_y \zeta \in \mathbb{R}^{d_y},$$

여기서

$$z \in \mathbb{R}_+^{K_s}, \quad \xi \in \mathbb{R}_+^{K_x}, \quad \zeta \in \mathbb{R}_+^{K_y},$$

이고 $\xi \perp \zeta \mid z$ 이다.

z는 두 모달에 공통인 shared generative factor, ξ, ζ는 각 모달의 private factor이다.

Definition 2 (Blockwise Top-K multimodal SAE)

공유 블록 폭을 m_s, 이미지 private 블록 폭을 m_x, 텍스트 private 블록 폭을 m_y라 하자.
$T_k(u) := \mathrm{TopK}_k(\mathrm{ReLU}(u))$ 로 둔다.

이미지 뷰의 encoder:

$$s_x(x) = T_1(E_s^x x) \in \mathbb{R}^{m_s}, \qquad p_x(x) = T_{k_x}(E_x x) \in \mathbb{R}^{m_x}.$$

텍스트 뷰의 encoder:

$$s_y(y) = T_1(E_s^y y) \in \mathbb{R}^{m_s}, \qquad q_y(y) = T_{k_y}(E_y y) \in \mathbb{R}^{m_y}.$$

decoder는

$$\hat{x} = D_s^x s_x(x) + D_x p_x(x), \qquad \hat{y} = D_s^y s_y(y) + D_y q_y(y).$$

여기서 **shared block은 Top-1**로 두었다.
이건 Top-K setting의 가장 깔끔한 special case이고, 아래 정리는 이 경우 완전증명이 된다.

Definition 3 (Objective)

$$L_{\mathrm{rec}}(\theta) = \mathbb{E}\big[\|x - \hat{x}\|_2^2 + \|y - \hat{y}\|_2^2\big],$$
$$L_{\mathrm{agree}}(\theta) = \mathbb{E}\big[\|s_x(x) - s_y(y)\|_2^2\big],$$
$$L_\lambda(\theta) = L_{\mathrm{rec}}(\theta) + \lambda L_{\mathrm{agree}}(\theta), \qquad \lambda > 0.$$

---

2. 먼저 밝혀야 하는 no-go

이 부분이 중요합니다.
Top-K에서 shared agreement만으로 identifiability를 주장하면 반례가 있습니다.

Proposition 0 (Agreement alone is insufficient)

encoder class가 충분히 expressive해서 private block이 shared factor까지 흡수할 수 있다고 하자.
그렇다면

$$s_x(x) \equiv 0, \qquad s_y(y) \equiv 0$$

로 두고, private code가 shared factor를 대신 저장하게 하면

$$L_{\mathrm{rec}} = 0, \qquad L_{\mathrm{agree}} = 0$$

인 split solution이 존재할 수 있다.

Proof
가령 private code가

$$p_x(x) = (z, \xi), \qquad q_y(y) = (z, \zeta)$$

를 표현할 수 있고 decoder를

$$D_x = [A_s \ A_x], \qquad D_y = [B_s \ B_y]$$

로 두면

$$\hat{x} = A_s z + A_x \xi = x, \qquad \hat{y} = B_s z + B_y \zeta = y.$$

또 shared code는 양쪽 모두 0이므로

$$L_{\text{agree}} = \mathbb{E}\|0 - 0\|_2^2 = 0.$$

따라서 agreement alone은 shared GT recovery를 보장하지 못한다. ∎

이 명제가 왜 중요한가 하면, 네가 논문에서 **반드시** 이렇게 써야 하기 때문입니다.

> "In the pure Top-K setting, pairwise agreement on the shared block alone is insufficient to ensure identifiability; one additionally needs a mechanism that forces actual usage of the shared block."

이 한 줄이 들어가야 뒤의 theorem이 훨씬 신뢰를 얻습니다.

---

3. agreement가 실제로 보장하는 것: nuisance-invariance

이제 진짜 핵심입니다.
shared block이 실제로 쓰인다고 가정하면, agreement는 shared code를 private nuisance로부터 떼어냅니다.

Lemma 1 (Exact agreement implies shared invariance)

가정:

$$\xi \perp \zeta \mid z.$$

또

$$s_x(x) = s_y(y) \quad \text{a.s.}$$

라고 하자. 그러면 어떤 measurable function ϕ가 존재해서

$$s_x(x) = s_y(y) = \phi(z) \quad \text{a.s.}$$

가 성립한다.

Proof
벡터의 각 좌표별로 보이면 충분하다. 임의의 좌표 ℓ에 대해

$$U := s_{x,\ell}(x) = s_{y,\ell}(y) \quad \text{a.s.}$$

라 두자.

그러면 조건부 독립성 때문에

$$\mathbb{E}[U^2 \mid z] = \mathbb{E}[s_{x,\ell}(x) s_{y,\ell}(y) \mid z] = \mathbb{E}[s_{x,\ell}(x) \mid z]\, \mathbb{E}[s_{y,\ell}(y) \mid z].$$

그런데 $U = s_{x,\ell}(x) = s_{y,\ell}(y)$ a.s. 이므로

$$\mathbb{E}[s_{x,\ell}(x) \mid z] = \mathbb{E}[s_{y,\ell}(y) \mid z] = \mathbb{E}[U \mid z].$$

따라서

$$\mathbb{E}[U^2 \mid z] = \mathbb{E}[U \mid z]^2.$$

즉

$$\mathrm{Var}(U \mid z) = 0.$$

그러므로 U는 z-measurable이고, 어떤 함수 ϕ_ℓ가 존재하여

$$U = \phi_\ell(z) \quad \text{a.s.}$$

벡터 전체에 대해 $\phi = (\phi_\ell)_\ell$ 를 모으면

$$s_x(x) = s_y(y) = \phi(z) \quad \text{a.s.}$$

이다. ∎

이 Lemma가 네가 원한 문장을 정확히 줍니다.

> **pairwise shared-code agreement가 0이면, learned shared code는 private factor가 아니라 shared generative factor z의 함수가 된다.**

이게 바로 “anchoring”의 수학적 핵심입니다.

---

4. 해집합 축소 정리

이제 “non-identifiable exact reconstruction 해집합이 줄어든다”를 깔끔하게 쓸 수 있습니다.

Theorem 1 (Solution-set shrinkage under exact realizability)

정확복원 해집합을

$$\Theta_0 := \{\theta : L_{\mathrm{rec}}(\theta) = 0\}$$

라 하고,
정확복원 + exact agreement 해집합을

$$\Theta_{\mathrm{align}} := \{\theta : L_{\mathrm{rec}}(\theta) = 0,\ L_{\mathrm{agree}}(\theta) = 0\}$$

라 하자.

만약 $\Theta_{\text{align}} \neq \varnothing$ 이면, 모든 $\lambda > 0$에 대해

$$\operatorname*{argmin}_{\theta} L_\lambda(\theta) = \Theta_{\text{align}}.$$

Proof
우선 $L_{\text{rec}} \geq 0$, $L_{\text{agree}} \geq 0$ 이므로 $L_\lambda \geq 0$.
또 $\Theta_{\text{align}} \neq \varnothing$ 이므로 어떤 $\theta^\star$에 대해

$$L_{\text{rec}}(\theta^\star) = 0, \qquad L_{\text{agree}}(\theta^\star) = 0,$$

즉

$$L_\lambda(\theta^\star) = 0.$$

따라서 L_λ의 최솟값은 0이다.

이제 임의의 θ가 L_λ의 global minimizer라고 하자. 그러면

$$0 = L_\lambda(\theta) = L_{\text{rec}}(\theta) + \lambda L_{\text{agree}}(\theta).$$

두 항이 모두 음이 아니므로

$$L_{\text{rec}}(\theta) = 0, \qquad L_{\text{agree}}(\theta) = 0.$$

즉 $\theta \in \Theta_{\text{align}}$.

반대로 $\theta \in \Theta_{\text{align}}$ 이면

$$L_\lambda(\theta) = 0$$

이므로 global minimizer이다. 따라서

$$\operatorname*{argmin}_{\theta} L_\lambda(\theta) = \Theta_{\text{align}}.$$

∎

Corollary 1

Theorem 1과 Lemma 1을 결합하면, Θ_{align} 안의 모든 해는

$$s_x(x) = s_y(y) = \phi(z)$$

형태를 만족한다.
즉, **augmentation은 exact reconstruction 해집합 중 shared code가 private nuisance에 의존하는 모든 해를 제거한다.**

---

5. finite-λ에서도 나오는 정량적 anchoring

실제로는 $L_{\text{agree}} = 0$까지 안 가는 경우가 많으니, 이 버전도 같이 넣는 게 좋습니다.

Proposition 1 (Finite-λ approximate anchoring bound)

$\Theta_{\text{align}} \neq \varnothing$ 이라 하자.
어떤 θ가

$$L_\lambda(\theta) \leq \delta$$

를 만족하면

$$\mathbb{E}\big\|s_x(x) - \mathbb{E}[s_x(x) \mid z]\big\|_2^2 + \mathbb{E}\big\|s_y(y) - \mathbb{E}[s_y(y) \mid z]\big\|_2^2 \leq \frac{\delta}{\lambda}.$$

Proof
Theorem 1의 가정 아래 최적값은 0이므로

$$L_{\text{rec}}(\theta) + \lambda L_{\text{agree}}(\theta) \leq \delta \quad \Longrightarrow \quad L_{\text{agree}}(\theta) \leq \frac{\delta}{\lambda}.$$

이제

$$U := s_x(x), \qquad V := s_y(y)$$

라 두자. 조건부 독립성 $x \perp y \mid z$ 에 의해 $U \perp V \mid z$. 따라서

$$\mathbb{E}\big[\|U - V\|_2^2 \mid z\big] = \mathbb{E}\big[\|U - \mathbb{E}[U \mid z]\|_2^2 \mid z\big] + \mathbb{E}\big[\|V - \mathbb{E}[V \mid z]\|_2^2 \mid z\big] + \big\|\mathbb{E}[U \mid z] - \mathbb{E}[V \mid$$

양변 expectation을 취하면

$$L_{\text{agree}}(\theta) = \mathbb{E}\|U - V\|_2^2$$
$$= \mathbb{E}\|U - \mathbb{E}[U \mid z]\|_2^2 + \mathbb{E}\|V - \mathbb{E}[V \mid z]\|_2^2 + \mathbb{E}\|\mathbb{E}[U \mid z] - \mathbb{E}[V \mid z]\|_2^2.$$

마지막 항은 음이 아니므로

$$\mathbb{E}\|U - \mathbb{E}[U \mid z]\|_2^2 + \mathbb{E}\|V - \mathbb{E}[V \mid z]\|_2^2 \leq L_{\text{agree}}(\theta) \leq \frac{\delta}{\lambda}.$$

∎

이건 실험 섹션과도 아주 잘 맞습니다.
λ를 키우면 shared code가 점점 z-measurable한 방향으로 밀린다는 걸 정량적으로 써줄 수 있습니다.

---

6. 이제 GT shared atom까지 식별하는 완전정리

여기서부터는 **Top-K 완전증명**을 위해 가정을 조금 더 둡니다.
가장 깔끔한 건 **shared block을 Top-1**로 두고, 각 shared GT atom이 단독으로 나타나는 anchor state가 있다고 가정하는 것입니다.

Assumption A (Singleton shared anchor states)

각 $j \in [K_s]$에 대해, 양의 measure를 갖는 구간 $I_j \subset (0, \infty)$ 가 존재하여

$$z = \alpha e_j, \qquad \xi = 0, \qquad \zeta = 0, \qquad \alpha \in I_j$$

인 paired sample이 존재한다고 하자.

즉, 각 shared GT feature는 **단독으로 나타나는 anchor state**를 가진다.

Assumption B (Unique Top-1 response on shared atoms)

각 j에 대해

$$E_s^x A_s[:, j], \qquad E_s^y B_s[:, j]$$

는 각각 **유일한 양의 최댓값 좌표**를 갖는다.

Assumption C (Private silence on shared anchor states)

모든 $\alpha \in I_j$ 에 대해

$$p_x(A_s \alpha e_j) = 0, \qquad q_y(B_s \alpha e_j) = 0.$$

이건 pure shared state에서 private block이 켜지지 않는다는 가정입니다.
실제로는 이 역할을

- blockwise budget 설계,
- 혹은 shared-only cross reconstruction
  중 하나가 대신 해줄 수 있습니다.

Assumption D (Non-collinearity of shared atoms)

$$A_s[:, j_1] \nparallel A_s[:, j_2], \qquad B_s[:, j_1] \nparallel B_s[:, j_2] \quad (j_1 \neq j_2).$$

Theorem 2 (Shared atom identifiability in the singleton Top-1 regime)

Assumptions A–D가 성립한다고 하자.
또 어떤 θ가

$$L_{\text{rec}}(\theta) = 0, \qquad L_{\text{agree}}(\theta) = 0$$

를 만족한다고 하자.

그러면 각 shared GT atom $j \in [K_s]$에 대해, 어떤 index $\pi(j) \in [m_s]$와 어떤 양수 $c_j > 0$가 존재하여 모든 $\alpha \in I_j$에 대해

$$s_x(A_s \alpha e_j) = s_y(B_s \alpha e_j) = c_j \alpha \, e_{\pi(j)}.$$

또

$$D_s^x[:, \pi(j)] = \frac{A_s[:, j]}{c_j}, \qquad D_s^y[:, \pi(j)] = \frac{B_s[:, j]}{c_j}.$$

추가로 π는 injective이다. 특히 $m_s = K_s$이면 π는 permutation이다.

즉, **learned shared decoder는 GT shared atom을 column-wise로 포함하며, perm/positive-scale까지 식별된다.**

Proof
고정된 $j \in [K_s]$를 잡자.
anchor state에서는

$$x = A_s \alpha e_j = \alpha a_j, \qquad y = B_s \alpha e_j = \alpha b_j$$

라고 쓸 수 있다. 여기서

$$a_j := A_s[:, j], \qquad b_j := B_s[:, j].$$

shared encoder는 Top-1 + ReLU 이므로 positive homogeneity를 가진다:

$$T_1(\alpha u) = \alpha T_1(u) \qquad (\alpha > 0).$$

또 Assumption B에 의해 $T_1(E_s^x a_j)$, $T_1(E_s^y b_j)$는 각각 정확히 하나의 양의 좌표만 가진다. 따라서 어떤 $\rho_j^x, \rho_j^y > 0$와 어떤 index $\pi_x(j), \pi_y(j)$가 존재하여

$$T_1(E_s^x a_j) = \rho_j^x e_{\pi_x(j)}, \qquad T_1(E_s^y b_j) = \rho_j^y e_{\pi_y(j)}.$$

positive homogeneity에 의해 모든 $\alpha \in I_j$에 대해

$$s_x(\alpha a_j) = \alpha \rho_j^x e_{\pi_x(j)}, \qquad s_y(\alpha b_j) = \alpha \rho_j^y e_{\pi_y(j)}.$$

이제 $L_{\text{agree}} = 0$ 이므로 a.s.

$$s_x(x) = s_y(y).$$

특히 anchor state에서는

$$\alpha \rho_j^x e_{\pi_x(j)} = \alpha \rho_j^y e_{\pi_y(j)}.$$

$\alpha > 0$ 이므로

$$\rho_j^x e_{\pi_x(j)} = \rho_j^y e_{\pi_y(j)}.$$

따라서

$$\pi_x(j) = \pi_y(j) =: \pi(j), \qquad \rho_j^x = \rho_j^y =: c_j > 0.$$

즉

$$s_x(\alpha a_j) = s_y(\alpha b_j) = c_j \alpha e_{\pi(j)}.$$

이제 $L_{\text{rec}} = 0$ 와 Assumption C를 쓰면, anchor state에서 private block이 0이므로

$$\alpha a_j = D_s^x s_x(\alpha a_j) = D_s^x (c_j \alpha e_{\pi(j)}) = c_j \alpha \, D_s^x[:, \pi(j)].$$

$\alpha > 0$ 이므로

$$a_j = c_j\, D_s^x[:, \pi(j)].$$

즉

$$D_s^x[:, \pi(j)] = \frac{a_j}{c_j} = \frac{A_s[:, j]}{c_j}.$$

같은 방식으로

$$D_s^y[:, \pi(j)] = \frac{B_s[:, j]}{c_j}.$$

마지막으로 π가 injective임을 보이자.
만약 서로 다른 $j_1 \neq j_2$에 대해 $\pi(j_1) = \pi(j_2) = i$ 라면

$$D_s^x[:, i] = \frac{A_s[:, j_1]}{c_{j_1}} = \frac{A_s[:, j_2]}{c_{j_2}}.$$

그러면 $A_s[:, j_1]$와 $A_s[:, j_2]$가 서로 collinear해야 한다. 이는 Assumption D와 모순이다.
따라서 π는 injective이다. $m_s = K_s$이면 injective map은 permutation이다. ∎

---

7. 이 정리가 정확히 무엇을 말해 주는가

이제 네가 논문에서 쓰고 싶은 핵심 문장을 아주 정확하게 적을 수 있습니다.

논문용 핵심 claim 1

Reconstruction alone is not enough.
Even in the Top-K setting, reconstruction with a shared/private split admits degenerate split solutions in which shared semantics are encoded into modality-private units.

논문용 핵심 claim 2

Agreement is an endogenous anchor.
Among exact-reconstruction solutions, the shared-code agreement term removes every solution whose shared code depends on modality-specific nuisance factors; the remaining shared code must be a function of the shared generative factor z.

논문용 핵심 claim 3

With a shared-usage mechanism, the shared block aligns to GT shared atoms.
In the singleton-anchor Top-1 regime, exact reconstruction plus shared-code agreement identifies the shared decoder atoms up to permutation and positive scaling.

논문용 핵심 claim 4

Finite λ still yields approximate anchoring.
If the augmented loss is within δ of the optimum, the conditional variance of the learned shared code given z is at most $O(\delta/\lambda)$.

---

8. 네 질문에 대한 아주 직접적인 답

네가 보이고 싶은

> "멀티뷰 구조를 이용한 보조 목적이 SAE의 비식별성을 줄이고, shared GT feature 쪽으로 해를 앵커링한다"

는 **이론적으로 충분히 보일 수 있습니다.**

하지만 **정확한 명제는 아래처럼 써야 맞습니다.**

- **거짓인 버전**:
  "pairwise agreement만 넣으면 항상 GT shared feature를 recover한다."
- **참으로 만들 수 있는 버전**:
  "pairwise agreement는 exact-reconstruction 해집합을 shared-nuisance-invariant 해들로 축소한다.
  그리고 shared block이 실제로 쓰이도록 하는 추가 구조와 singleton shared anchor state 가정 아래에서는 shared decoder atoms가 GT shared atoms에 perm/scale까지 정렬된다."

이게 제일 깔끔하고, 이론적으로도 가장 안전합니다.

---

9. 현실적으로 추천하는 paper 구조

나는 이 순서를 추천합니다.

1. **No-go proposition**: agreement alone is insufficient.
2. **Lemma**: exact agreement $\Rightarrow$ shared code is z-measurable.
3. **Theorem**: exact-reconstruction solution set shrinkage.
4. **Finite-λ proposition**: approximate anchoring bound.
5. **Main identifiability theorem**: singleton-anchor Top-1 regime에서 shared atom recovery.

이렇게 쓰면,

- 왜 멀티모달이 더 어려운지,
- 왜 네 auxiliary가 필요한지,
- 그 auxiliary가 정확히 무엇을 보장하는지
  가 논리적으로 딱 닫힙니다.

원하면 다음 답변에서 내가 이걸 바로 **LaTeX theorem/proof 환경으로 옮긴 버전**으로 정리해주겠습니다.

Sources

고마워 근데 notation들이 너무 설명 없이 나온 것 같아 예를 들어 top-1이 뭔데. notation들은 정의, loss 같은 것도 식이 뭔지 이런 걸 다 적어줄래? 그래서 다시 정리해줘

Thought for 24m 28s ›

좋아. 이번에는 **notation을 처음부터 전부 정의**하고, **loss도 식으로 명시**하고, 그 위에서 **정리–가정–증명**이 자연스럽게 이어지도록 다시 쓸게.

세 논문과 네 draft를 같이 보면, 가장 안전한 이론적 framing은 이거야.
2512.05534는 SDL/SAE가 구조적으로 underdetermined라서 **perfect reconstruction이 곧 GT feature recovery를 뜻하지 않으며**, spurious partial minima와 polysemantic failure가 널리 생긴다고 본다. 2506.15963는 SAE identifiability가 일반적으로는 성립하지 않고 **extreme sparsity 같은 강한 조건**에서만 clean하게 나옴을 분석한다. 2602.06218는 multimodal setting에서 alignment-style inductive bias가 **재구성 성능을 크게 해치지 않으면서** GT bimodal structure recovery를 돕는 toy sanity check를 제시한다. 네 PDF도 이 흐름 위에서 **shared/private 분할 + shared-code agreement**를 핵심 구조로 잡고 있다.

아래는 그걸 **Top-K activation만 쓰는 버전**으로, 논문 본문에 바로 넣을 수 있게 self-contained하게 다시 정리한 것이다.

---

0. 목표 문장

우리가 보이고 싶은 것은 다음이다.

> **멀티뷰(pair) 구조를 이용한 shared-code agreement 보조 목적은, reconstruction-only에서 남아 있던 비식별 해집합을 줄이고, learned shared code를 shared generative factor 쪽으로 앵커링한다.**
> 추가로, shared block이 실제로 사용되도록 하는 조건까지 넣으면 learned shared decoder atom은 GT shared atom에 permutation/positive scaling까지 정렬된다.

---

1. 기본 notation

먼저 가장 기본 기호부터 정의하자.

- $x \in \mathbb{R}^{d_x}$: 이미지 뷰의 representation 또는 embedding
- $y \in \mathbb{R}^{d_y}$: 텍스트 뷰의 representation 또는 embedding
- (x, y): paired sample
- $z \in \mathbb{R}_+^{K_s}$: **shared** ground-truth latent
- $\xi \in \mathbb{R}_+^{K_x}$: image-private ground-truth latent
- $\zeta \in \mathbb{R}_+^{K_y}$: text-private ground-truth latent

여기서 $\mathbb{R}_+ = [0, \infty)$ 이고, nonnegative latent를 가정한다.

또 다음 notation을 쓴다.

- $\mathrm{supp}(v) = \{i : v_i \neq 0\}$: 벡터 v의 support
- $\|v\|_0 = |\mathrm{supp}(v)|$: nonzero 좌표 개수
- e_j: j-번째 standard basis vector
- "a.s.": almost surely
- "GT": ground truth

---

2. 생성모형: shared/private multiview LRH

Assumption 1 (Shared–private multiview generative model)

paired sample (x, y)가 다음과 같이 생성된다고 하자:

$$x = A_s z + A_x \xi \in \mathbb{R}^{d_x}, \qquad y = B_s z + B_y \zeta \in \mathbb{R}^{d_y}.$$

여기서

- $A_s \in \mathbb{R}^{d_x \times K_s}$: image 쪽 **shared GT dictionary**
- $A_x \in \mathbb{R}^{d_x \times K_x}$: image 쪽 **private GT dictionary**
- $B_s \in \mathbb{R}^{d_y \times K_s}$: text 쪽 **shared GT dictionary**
- $B_y \in \mathbb{R}^{d_y \times K_y}$: text 쪽 **private GT dictionary**

이다.

또 private nuisance는 shared latent를 조건으로 독립이라고 가정한다:

$$\xi \perp \zeta \mid z.$$

이 가정에서 곧바로

$$x \perp y \mid z$$

가 성립한다.

이건 "두 뷰의 의존성은 shared factor z를 통해서만 생긴다"는 뜻이다.

---

3. Top-K operator 정의

이제 Top-K를 정확히 정의하자.

Definition 1 (ReLU)

벡터 $u \in \mathbb{R}^m$에 대해

$$[\mathrm{ReLU}(u)]_i := \max\{u_i, 0\}.$$

Definition 2 (Top-K after ReLU)

벡터 $u \in \mathbb{R}^m$와 정수 $k \in \{1, \dots, m\}$에 대해,
$\mathrm{ReLU}(u)$의 좌표 중 **값이 큰 상위 k개 좌표만 남기고 나머지를 0으로 만드는 연산**을

$$\Pi_k(u) := \mathrm{TopK}_k(\mathrm{ReLU}(u))$$

로 정의한다.

즉, $\mathrm{ReLU}(u)$의 상위 k개 좌표 index 집합을 $I_k(u)$라고 쓰면,

$$[\Pi_k(u)]_i = \begin{cases} [\mathrm{ReLU}(u)]_i, & i \in I_k(u), \\ 0, & i \notin I_k(u). \end{cases}$$

tie는 거의 surely 일어나지 않는다고 가정하자.

이 정의에서 바로

$$\|\Pi_k(u)\|_0 \le k$$

이고, 각 좌표는

$$[\Pi_k(u)]_i \in \{0,\ [\mathrm{ReLU}(u)]_i\}$$

이다.

즉 Top-K는 "값을 새로 만들지 않고, **살리거나 0으로 죽이는 선택 연산**"이다.

Definition 3 (Top-1)

$k = 1$인 특수한 경우를 **Top-1**이라 부른다:

$$\Pi_1(u) = \mathrm{TopK}_1(\mathrm{ReLU}(u)).$$

이 경우, ReLU 후 가장 큰 **하나의 양의 좌표만** 살아남는다.

예를 들어

$$u = (2, -1, 0.5, 3)$$

이면

$$\mathrm{ReLU}(u) = (2, 0, 0.5, 3),$$

$$\Pi_2(u) = (2, 0, 0, 3), \qquad \Pi_1(u) = (0, 0, 0, 3).$$

---

4. blockwise Top-K multimodal SAE

이제 latent를 shared / image-private / text-private 세 블록으로 나눈다.

Definition 4 (Latent block sizes)

learned latent dimension을 세 블록으로 나누자:

- shared block width: M_s

- image-private block width: M_x
- text-private block width: M_y

Definition 5 (Encoders)

encoder parameter를

$$E_s^x \in \mathbb{R}^{M_s \times d_x}, \quad E_x \in \mathbb{R}^{M_x \times d_x},$$
$$E_s^y \in \mathbb{R}^{M_s \times d_y}, \quad E_y \in \mathbb{R}^{M_y \times d_y}$$

로 둔다.

blockwise sparsity budget을

$$k_s, \quad k_x, \quad k_y$$

로 둔다.

그러면 이미지 입력 x의 learned code는

$$s_x(x) := \Pi_{k_s}(E_s^x x) \in \mathbb{R}^{M_s},$$
$$p_x(x) := \Pi_{k_x}(E_x x) \in \mathbb{R}^{M_x}.$$

텍스트 입력 y의 learned code는

$$s_y(y) := \Pi_{k_s}(E_s^y y) \in \mathbb{R}^{M_s},$$
$$q_y(y) := \Pi_{k_y}(E_y y) \in \mathbb{R}^{M_y}.$$

여기서

- $s_x(x), s_y(y)$: learned **shared code**
- $p_x(x)$: learned image-private code
- $q_y(y)$: learned text-private code

이다.

중요한 점은 **global Top-K를 한 번 하는 게 아니라**, 각 block에 대해 따로 Top-K를 적용한다는 것이다.

즉,

$$\|s_x(x)\|_0 \le k_s, \quad \|p_x(x)\|_0 \le k_x,$$
$$\|s_y(y)\|_0 \le k_s, \quad \|q_y(y)\|_0 \le k_y.$$

이걸 **blockwise Top-K budgets**라고 부르자.

Definition 6 (Decoders and reconstructions)

decoder parameter를

$$D_s^x \in \mathbb{R}^{d_x \times M_s}, \quad D_x \in \mathbb{R}^{d_x \times M_x},$$

$$D_s^y \in \mathbb{R}^{d_y \times M_s}, \quad D_y \in \mathbb{R}^{d_y \times M_y}$$

로 둔다.

reconstruction은

$$\hat{x} = D_s^x s_x(x) + D_x p_x(x),$$
$$\hat{y} = D_s^y s_y(y) + D_y q_y(y).$$

즉 shared block과 private block을 각각 decode해서 더한다.

전체 parameter 집합은

$$\theta := (E_s^x, E_x, E_s^y, E_y, D_s^x, D_x, D_s^y, D_y)$$

로 쓴다.

---

5. Loss 정의

Definition 7 (Reconstruction loss)

$$L_{\mathrm{rec}}(\theta) := \mathbb{E}\big[\|x - \hat{x}\|_2^2 + \|y - \hat{y}\|_2^2\big].$$

Definition 8 (Shared-code agreement loss)

$$L_{\mathrm{agr}}(\theta) := \mathbb{E}\big[\|s_x(x) - s_y(y)\|_2^2\big].$$

이 loss는 paired image/text가 같은 shared factor를 가지고 있을 때, learned shared code도 서로 비슷해지도록 강제한다.

Definition 9 (Core Top-K objective)

$$L_\lambda(\theta) := L_{\mathrm{rec}}(\theta) + \lambda L_{\mathrm{agr}}(\theta), \qquad \lambda > 0.$$

이게 **Top-K-only core objective**다.

실전에서는 여기에 paired group term 같은 걸 더할 수도 있다. 예를 들면

$$R_{\mathrm{pair}}(\theta) := \mathbb{E}\Big[\sum_{i=1}^{M_s} \sqrt{s_{x,i}(x)^2 + s_{y,i}(y)^2}\Big]$$

를 추가해서 shared support가 pair에서 같이 켜지게 유도할 수 있다.
하지만 아래의 핵심 정리는 **순수하게** L_λ 만으로 서술하겠다.

---

6. 먼저 밝혀야 하는 no-go: agreement만으로는 부족하다

이건 꼭 먼저 적어야 한다. 안 그러면 뒤 theorem이 너무 강해 보여서 반례를 맞는다.

Proposition 0 (Agreement alone is insufficient)

private block이 충분히 expressive해서 shared factor까지 private block에 담을 수 있다고 하자. 그러면

$$s_x(x) \equiv 0, \qquad s_y(y) \equiv 0$$

인데도

$$L_{\mathrm{rec}}(\theta) = 0, \qquad L_{\mathrm{agr}}(\theta) = 0$$

를 동시에 만족하는 퇴행해가 존재할 수 있다.

Proof

가령 private block이

$$p_x(x) = (z, \xi), \qquad q_y(y) = (z, \zeta)$$

를 표현할 수 있다고 하자.

그때 decoder를 적절히 잡아서

$$\hat{x} = A_s z + A_x \xi = x, \qquad \hat{y} = B_s z + B_y \zeta = y$$

가 되게 할 수 있다.

한편 shared code는 양쪽 모두 항상 0이므로

$$L_{\mathrm{agr}}(\theta) = \mathbb{E}\|0 - 0\|_2^2 = 0.$$

따라서 **agreement 항만 넣었다고 해서 shared GT feature recovery가 자동으로 되는 것은 아니다.** ∎

이 명제가 말하는 건 아주 명확하다.

> reconstruction + agreement만으로는 “shared block을 실제로 쓰게 만드는 장치”가 부족할 수 있다.

그래서 아래 정리들은

1. agreement가 **무엇을 보장하는지**,
2. 거기에 더해 어떤 shared-usage 가정이 있으면 **GT shared atom recovery**까지 가는지

를 분리해서 말한다.

이 방향은 네 PDF가 말하는 blockwise Top-K necessity와도 일치한다.

---

7. agreement가 정확히 보장하는 것: nuisance-invariance

이제 가장 중요한 lemma다.

Lemma 1 (Exact agreement forces dependence only on the shared factor)

Assumption 1 아래에서,

$$s_x(x) = s_y(y) \quad \text{a.s.}$$

라고 하자. 그러면 어떤 measurable function

$$\phi : \mathbb{R}_+^{K_s} \to \mathbb{R}^{M_s}$$

가 존재해서

$$s_x(x) = s_y(y) = \phi(z) \quad \text{a.s.}$$

가 성립한다.

즉, shared code는 private nuisance ξ, ζ의 함수가 아니라 **오직 shared latent z의 함수**가 된다.

Proof

각 좌표별로 보이면 충분하다. shared code의 임의의 좌표 $\ell \in \{1, \dots, M_s\}$를 잡고

$$U := s_{x,\ell}(x), \qquad V := s_{y,\ell}(y)$$

라고 두자.

가정에 의해

$$U = V \quad \text{a.s.}$$

또 Assumption 1에서 $\xi \perp \zeta \mid z$ 이므로

$$x \perp y \mid z,$$

따라서

$$U \perp V \mid z.$$

이제 조건부 기댓값을 계산하면

$$\mathbb{E}[U^2 \mid z] = \mathbb{E}[UV \mid z] = \mathbb{E}[U \mid z]\mathbb{E}[V \mid z].$$

그런데 $U = V$ a.s. 이므로

$$\mathbb{E}[U \mid z] = \mathbb{E}[V \mid z].$$

따라서

$$\mathbb{E}[U^2 \mid z] = \mathbb{E}[U \mid z]^2.$$

즉

$$\mathrm{Var}(U \mid z) = 0.$$

조건부 분산이 0이라는 것은 U가 z-measurable이라는 뜻이다. 따라서 어떤 함수 ϕ_ℓ가 존재해서

$$U = \phi_\ell(z) \quad \text{a.s.}$$

이다.

이걸 모든 좌표 ℓ에 대해 모으면 어떤 벡터값 함수 ϕ가 존재하여

$$s_x(x) = s_y(y) = \phi(z) \quad \text{a.s.}$$

를 얻는다. ∎

이 Lemma가 네가 원한 "anchoring"의 핵심 수학적 진술이다.

---

8. 해집합 축소: reconstruction-only보다 작은 해집합

이제 "non-identifiable 해집합이 줄어든다"를 정확히 적을 수 있다.

Definition 10 (Exact-reconstruction solution sets)

reconstruction만 0이 되는 해집합을

$$\Theta_{\text{rec}} := \{\theta : L_{\text{rec}}(\theta) = 0\}$$

라고 하자.

reconstruction도 0이고 agreement도 0인 해집합을

$$\Theta_{\text{align}} := \{\theta : L_{\text{rec}}(\theta) = 0,\ L_{\text{agr}}(\theta) = 0\}$$

라고 하자.

Theorem 1 (Solution-set shrinkage)

$\Theta_{\text{align}} \neq \varnothing$ 라고 하자. 그러면 모든 $\lambda > 0$에 대해

$$\operatorname*{argmin}_{\theta} L_\lambda(\theta) = \Theta_{\text{align}}.$$

Proof

$L_{\text{rec}}(\theta) \geq 0$, $L_{\text{agr}}(\theta) \geq 0$ 이므로

$$L_\lambda(\theta) \geq 0.$$

또 $\Theta_{\text{align}} \neq \varnothing$ 이므로 어떤 $\theta^\star$에 대해

$$L_{\text{rec}}(\theta^\star) = 0, \qquad L_{\text{agr}}(\theta^\star) = 0.$$

따라서

$$L_\lambda(\theta^\star) = 0.$$

즉 L_λ의 global minimum value는 0이다.

이제 θ가 L_λ의 global minimizer라고 하자. 그러면

$$0 = L_\lambda(\theta) = L_{\text{rec}}(\theta) + \lambda L_{\text{agr}}(\theta).$$

두 항 모두 음이 아니므로

$$L_{\mathrm{rec}}(\theta) = 0, \qquad L_{\mathrm{agr}}(\theta) = 0.$$

즉 $\theta \in \Theta_{\mathrm{align}}$.

반대로 $\theta \in \Theta_{\mathrm{align}}$이면 당연히

$$L_\lambda(\theta) = 0$$

이므로 global minimizer이다.

따라서

$$\operatorname*{argmin}_\theta L_\lambda(\theta) = \Theta_{\mathrm{align}}.$$

∎

Corollary 1

Theorem 1과 Lemma 1을 합치면, Θ_{align} 안의 모든 해는

$$s_x(x) = s_y(y) = \phi(z) \quad \text{a.s.}$$

형태를 만족한다.

즉, **reconstruction-only에서 남아 있던 해들 중 shared code가 private nuisance에 의존하는 해는 모두 제거된다.**

---

9. finite λ일 때의 정량적 버전

exact agreement 대신 small agreement만 얻어도 “shared code가 nuisance로부터 멀어진다”는 걸 쓸 수 있다.

Proposition 1 (Approximate anchoring bound)

$\Theta_{\mathrm{align}} \neq \varnothing$ 이고 어떤 θ가

$$L_\lambda(\theta) \le \delta$$

를 만족한다고 하자. 그러면

$$\mathbb{E}\big\|s_x(x) - \mathbb{E}[s_x(x) \mid z]\big\|_2^2 + \mathbb{E}\big\|s_y(y) - \mathbb{E}[s_y(y) \mid z]\big\|_2^2 \le \frac{\delta}{\lambda}.$$

Proof

$\Theta_{\mathrm{align}} \neq \varnothing$ 이므로 최적값은 0이다. 따라서

$$L_\lambda(\theta) \le \delta \quad \Longrightarrow \quad L_{\mathrm{agr}}(\theta) \le \frac{\delta}{\lambda}.$$

이제

$$U := s_x(x), \qquad V := s_y(y)$$

라고 두자. $x \perp y \mid z$ 이므로 $U \perp V \mid z$ 이다. 따라서

$$\mathbb{E}\big[\|U-V\|_2^2 \mid z\big] = \mathbb{E}\big[\|U-\mathbb{E}[U \mid z]\|_2^2 \mid z\big] + \mathbb{E}\big[\|V-\mathbb{E}[V \mid z]\|_2^2 \mid z\big] + \|\mathbb{E}[U \mid z] - \mathbb{E}[V \mid$$

양변 expectation을 취하면

$$L_{\text{agr}}(\theta) = \mathbb{E}\|U-V\|_2^2$$
$$= \mathbb{E}\|U-\mathbb{E}[U \mid z]\|_2^2 + \mathbb{E}\|V-\mathbb{E}[V \mid z]\|_2^2 + \mathbb{E}\|\mathbb{E}[U \mid z] - \mathbb{E}[V \mid z]\|_2^2.$$

마지막 항은 음이 아니므로

$$\mathbb{E}\|U-\mathbb{E}[U \mid z]\|_2^2 + \mathbb{E}\|V-\mathbb{E}[V \mid z]\|_2^2 \le L_{\text{agr}}(\theta) \le \frac{\delta}{\lambda}.$$

∎

이건 실험적으로도 해석이 좋다. λ를 키우면 shared code가 점점 z-only representation이 되도록 압력을 받는다.

---

10. 이제 GT shared atom recovery까지 가는 완전한 정리

여기서부터는 **정말로 complete proof가 닫히는 special case**를 준다.
가장 깔끔한 건 **shared block에 Top-1을 쓰는 경우**다.

즉 이제부터는

$$k_s = 1$$

이라고 두자.

이 말은 shared block에서 **최대 하나의 활성만 남는다**는 뜻이다.

Assumption 2 (Shared block uses Top-1)

공유 블록은 Top-1을 사용한다:

$$s_x(x) = \Pi_1(E_s^x x), \qquad s_y(y) = \Pi_1(E_s^y y).$$

Assumption 3 (Singleton shared anchor states)

각 shared GT feature $j \in \{1, \dots, K_s\}$에 대해, 양의 measure를 갖는 interval $I_j \subset (0, \infty)$가 존재하여

$$z = \alpha e_j, \qquad \xi = 0, \qquad \zeta = 0, \qquad \alpha \in I_j$$

인 paired sample이 존재한다고 하자.

즉, 각 shared factor는 "혼자 켜지는" pure state를 가진다.

Assumption 4 (Unique positive Top-1 response on each shared atom)

각 j에 대해

$$E_s^x A_s[:, j] \in \mathbb{R}^{M_s}, \qquad E_s^y B_s[:, j] \in \mathbb{R}^{M_s}$$

는 각각 **유일한 양의 최댓값 좌표**를 가진다고 하자.

즉 Top-1이 어느 좌표를 고르는지가 모호하지 않다.

Assumption 5 (Private silence on pure shared anchor states)

모든 j와 모든 $\alpha \in I_j$에 대해

$$p_x(A_s \alpha e_j) = 0, \qquad q_y(B_s \alpha e_j) = 0.$$

이건 pure shared state에서는 private block이 꺼져 있다는 뜻이다.

Assumption 6 (Non-collinearity of shared atoms)

$j_1 \neq j_2$이면

$$A_s[:, j_1] \nparallel A_s[:, j_2], \qquad B_s[:, j_1] \nparallel B_s[:, j_2].$$

즉 서로 다른 shared GT atom들이 서로 scalar multiple이 아니다.

---

11. Main theorem

Theorem 2 (Shared atom identifiability in the Top-1 shared regime)

Assumptions 1–6이 성립하고, 어떤 θ가

$$L_{\text{rec}}(\theta) = 0, \qquad L_{\text{agr}}(\theta) = 0$$

를 만족한다고 하자.

그러면 각 $j \in \{1, \dots, K_s\}$에 대해

- 어떤 shared coordinate index $\pi(j) \in \{1, \dots, M_s\}$,
- 어떤 양수 $c_j > 0$

가 존재하여 모든 $\alpha \in I_j$에 대해

$$s_x(A_s \alpha e_j) = s_y(B_s \alpha e_j) = c_j \alpha \, e_{\pi(j)}.$$

또

$$D_s^x[:, \pi(j)] = \frac{A_s[:, j]}{c_j}, \qquad D_s^y[:, \pi(j)] = \frac{B_s[:, j]}{c_j}.$$

추가로 π는 injective이다. 특히 $M_s = K_s$이면 π는 permutation이다.

즉, learned shared decoder atoms는 GT shared atoms를 **permutation과 positive scaling 까지** 복원한다.

---

12. Theorem 2의 complete proof

Proof

고정된 $j \in \{1, \dots, K_s\}$를 잡자.

Assumption 3에 의해 pure shared anchor sample

$$x = A_s \alpha e_j = \alpha a_j, \qquad y = B_s \alpha e_j = \alpha b_j, \qquad \alpha \in I_j$$

를 취할 수 있다. 여기서

$$a_j := A_s[:, j], \qquad b_j := B_s[:, j].$$

Step 1. Top-1 shared code는 one-hot scaling 형태다

Top-1 operator Π_1는 $\alpha > 0$에 대해 positive homogeneity를 가진다:

$$\Pi_1(\alpha u) = \alpha \Pi_1(u).$$

왜냐하면 ReLU도 positive homogeneous이고, Top-1도 양수 배를 해도 argmax를 바꾸지 않기 때문이다.

이제 Assumption 4에 의해 $E_s^x a_j$는 ReLU 후 유일한 양의 최댓값 좌표를 가지므로, 어떤 $\rho_j^x > 0$와 어떤 index $\pi_x(j)$가 존재해서

$$\Pi_1(E_s^x a_j) = \rho_j^x e_{\pi_x(j)}.$$

따라서 모든 $\alpha > 0$에 대해

$$s_x(\alpha a_j) = \Pi_1(E_s^x(\alpha a_j)) = \Pi_1(\alpha E_s^x a_j) = \alpha \Pi_1(E_s^x a_j) = \alpha \rho_j^x e_{\pi_x(j)}.$$

같은 논리로 어떤 $\rho_j^y > 0$와 $\pi_y(j)$가 존재해서

$$s_y(\alpha b_j) = \alpha \rho_j^y e_{\pi_y(j)}.$$

Step 2. exact agreement가 두 뷰의 shared index와 scale을 맞춘다

$L_{\text{agr}}(\theta) = 0$ 이므로

$$s_x(x) = s_y(y) \quad \text{a.s.}$$

이다.

특히 지금 잡은 pure shared anchor sample에 대해

$$\alpha \rho_j^x e_{\pi_x(j)} = \alpha \rho_j^y e_{\pi_y(j)}.$$

$\alpha > 0$ 이므로

$$\rho_j^x e_{\pi_x(j)} = \rho_j^y e_{\pi_y(j)}.$$

표준 basis vector의 유일성에 의해

$$\pi_x(j) = \pi_y(j) =: \pi(j), \qquad \rho_j^x = \rho_j^y =: c_j > 0.$$

따라서

$$s_x(\alpha a_j) = s_y(\alpha b_j) = c_j \alpha e_{\pi(j)}.$$

Step 3. exact reconstruction이 shared decoder atom을 GT shared atom에 맞춘다

Assumption 5에 의해 pure shared anchor sample에서는 private code가 0이다:

$$p_x(\alpha a_j) = 0, \qquad q_y(\alpha b_j) = 0.$$

또 $L_{\text{rec}}(\theta) = 0$ 이므로 reconstruction은 exact하다. 따라서

$$\alpha a_j = \hat{x} = D_s^x s_x(\alpha a_j) + D_x p_x(\alpha a_j) = D_s^x(c_j \alpha e_{\pi(j)}) + D_x 0.$$

즉

$$\alpha a_j = c_j \alpha \, D_s^x[:, \pi(j)].$$

$\alpha > 0$ 이므로

$$a_j = c_j D_s^x[:, \pi(j)].$$

따라서

$$D_s^x[:, \pi(j)] = \frac{a_j}{c_j} = \frac{A_s[:, j]}{c_j}.$$

같은 방식으로

$$D_s^y[:, \pi(j)] = \frac{B_s[:, j]}{c_j}.$$

Step 4. π는 injective다

만약 $j_1 \neq j_2$인데도 $\pi(j_1) = \pi(j_2) = i$라고 하자.

그러면 위에서 얻은 식에 의해

$$D_s^x[:, i] = \frac{A_s[:, j_1]}{c_{j_1}} = \frac{A_s[:, j_2]}{c_{j_2}}.$$

즉

A_s[:,j_1] = \frac{c_{j_1}}{c_{j_2}}A_s[:,j_2},

그래서 A_s[:,j_1]\parallel A_s[:,j_2} 가 된다.

이는 Assumption 6과 모순이다.

따라서 π는 injective이다. 특히 $M_s = K_s$이면 injective map은 permutation이다. ∎

---

13. 이 정리가 정확히 무엇을 말해 주는가

이제 네가 논문에서 쓰고 싶은 문장을 아주 명확하게 쓸 수 있다.

논문용 Claim A

Reconstruction alone is non-identifiable.
reconstruction-only objective는 exact reconstruction을 달성하면서도 shared semantics를 private neuron에 밀어 넣는 해를 허용한다.

논문용 Claim B

Agreement provides an anchor.
exact agreement가 성립하면 learned shared code는 private nuisance의 함수가 아니라 shared latent z의 함수가 된다.

논문용 Claim C

Agreement shrinks the exact-reconstruction solution set.
reconstruction-only minimizer 집합에서 shared code가 private factor에 의존하는 해들이 제거된다.

논문용 Claim D

With shared usage on pure shared states, the shared decoder aligns to GT shared atoms.
Top-1 shared block + singleton anchor state 가정 아래, shared decoder atom은 GT shared atom에 permutation/positive scaling까지 정렬된다.

---

14. 왜 “global Top-K 하나만” 두면 안 되나

이건 논문에서 remark로 넣는 게 좋다.

Remark 1 (Why blockwise Top-K is needed)

만약 concatenated latent 전체에 대해 global Top-K 하나만 두고, shared/private budget을 따로 나누지 않으면,

- shared block을 항상 0으로 두어도
- private block만으로 reconstruction을 수행하는

퇴행해가 쉽게 살아남는다.

즉

$$s_x(x) \equiv 0, \qquad s_y(y) \equiv 0$$

이면 agreement loss는 자동으로 0이고, private block이 충분히 expressive하면 reconstruction 도 잘 맞출 수 있다.

따라서 **Top-K-only 이론에서는**

- blockwise Top-K budget,
- 또는 shared-only cross reconstruction 같은 shared-use forcing 구조

중 하나가 사실상 필요하다.

이건 네 draft의 직관과도 정확히 맞다.

---

15. 어떤 가정이 현실적이고, 어떤 가정이 강한가

마지막으로 가정의 현실성을 정리하면 이렇다.

비교적 현실적인 것

- Assumption 1의 $x \perp y \mid z$ 형태
  멀티뷰 latent variable model에서 아주 표준적이다.
- shared/private block 분할
- pairwise agreement loss
- finite-λ에서 approximate anchoring 해석

exact proof를 위해 강한 것

- Assumption 3: 각 shared factor가 혼자 나타나는 singleton anchor state
- Assumption 5: pure shared sample에서 private block이 완전히 0
- Assumption 2의 shared Top-1 special regime

즉, **완전한 closed-form identifiability theorem**을 얻으려면 가정이 강해진다.
하지만 이건 2506.15963가 말하는 “extreme sparsity에서만 identifiability가 clean해진다”는 그림과도 잘 맞는다. 2506.15963v2

---

16. 네 논문에 바로 넣기 좋은 최종 문장

아마 본문에서는 아래처럼 쓰는 게 제일 좋다.

> We first show that reconstruction alone is non-identifiable in the multiview SAE setting.
> We then prove that exact shared-code agreement across paired views forces the learned shared code to be a measurable function of the shared generative factor and hence invariant to modality-specific nuisance variables. Consequently, the agreement term shrinks the exact-reconstruction solution set by eliminating solutions whose shared codes depend on private factors. Finally, under a singleton-anchor Top-1 shared regime with shared-block usage on pure shared states, the learned shared decoder atoms recover the ground-truth shared atoms up to permutation and positive scaling.

원하면 다음 답변에서는 이 내용을 그대로 **LaTeX theorem / proof 환경**으로 바꿔서, 바로 논문 초안에 붙일 수 있는 형태로 정리해줄게.

Sources